

Laporan Pipeline: Deteksi Deepfake Audio Bahasa Indonesia

Tanggal: 17 April 2026
Notebook: [pipeline_lengkap.ipynb](#)
Bahasa: Python 3.10.12 | PyTorch 2.11.0 | Device: Apple MPS

Daftar Isi

- 1. Ringkasan Eksekutif
- 2. Konfigurasi Global
- 3. Preprocessing Audio Bona Fide
- 4. Generasi Audio Spoof
- 5. Pembagian Dataset
- 6. Training Model AASIST
- 7. Training Model MoLEx
- 8. Perbandingan AASIST vs MoLEx
- 9. Inference Real-World
- 10. Ekstraksi Fitur untuk XGBoost
- 11. Training & Evaluasi XGBoost
- 12. Perbandingan Tiga Model
- 13. Catatan & Temuan Penting
- 14. Rekomendasi Lanjutan

1. Ringkasan Eksekutif

Pipeline ini membangun sistem deteksi deepfake audio Bahasa Indonesia end-to-end: mulai dari pengumpulan data, generasi audio sintetis (spoof), pelatihan tiga jenis model, hingga inferensi real-world. Dataset bersumber dari **Mozilla Common Voice v24.0** (Indonesian, 30.256 sampel) yang kemudian diperkaya dengan 75.512 sampel spoof dari 4 TTS engine berbeda.

Hasil akhir menunjukkan bahwa dua pendekatan berbasis fitur — MoLEx (LFCC) dan XGBoost (MFCC + akustik) — mencapai performa mendekati sempurna, sementara AASIST (raw waveform) masih tertinggal jauh, mengindikasikan bahwa fitur domain frekuensi jauh lebih diskriminatif untuk dataset ini.

Model	Accuracy	ROC-AUC	EER
AASIST	79.81%	0.9909	1.02%
MoLEx	99.95%	1.0000	0.03%
XGBoost	99.83%	1.0000	0.13%

2. Konfigurasi Global

Direktori Utama

Variabel	Path
CV_CORPUS_ROOT	/Users/rej/ITB/semester_2/PPT/dataset
DATASET_ROOT	/Users/rej/ITB/semester_2/PPT/dataset_voice
MODELS_ROOT	/Users/rej/ITB/semester_2/PPT/models_voice

Parameter Audio

Parameter	Nilai
Sample rate	16.000 Hz
Durasi maksimum	4 detik (64.000 sampel)
Format output	FLAC (PCM_16)

Parameter LFCC (MoLEx)

Parameter	Nilai
n_lfcc	60
n_filter	70
n_fft	512
win_length	320
hop_length	160

Hyperparameter Training (DL)

Parameter	Nilai
Batch size (AASIST)	24
Batch size (MoLEx)	32
Epochs	20
Learning rate	1e-4
Weight decay	1e-4
Optimizer	AdamW
Scheduler	CosineAnnealingLR (T_max=20)
Early stopping patience	5

Hyperparameter XGBoost

Parameter	Nilai
<code>max_depth</code>	6
<code>learning_rate</code>	0.1
<code>subsample</code>	0.8
<code>colsample_bytree</code>	0.8
CV folds	10
Boosting rounds (optimal)	230

3. Preprocessing Audio Bona Fide

Sumber data: Mozilla Common Voice v24.0 — korpus Bahasa Indonesia

File TSV yang dibaca: `validated.tsv`, `train.tsv`, `test.tsv`

Proses

1. Baca semua TSV menggunakan `csv.DictReader`
2. Deduplikasi berdasarkan tuple (`prefix`, `audio_filename`)
3. Load audio dengan `librosa.load(sr=16000, mono=True)`
4. Simpan ulang sebagai FLAC (PCM_16) ke direktori `bona_fide/`
5. Tulis metadata TSV: `[file_id, flac_filename, sentence]`

Hasil

File TSV	Records	Duplikat
<code>validated.tsv</code>	30.256	0
<code>train.tsv</code>	4.973	4.973 (semua duplikat dari validated)
<code>test.tsv</code>	3.691	3.691 (semua duplikat dari validated)
Total unik	30.256	—

- Output: `/Users/rei/ITB/semester_2/PPT/dataset_voice/bona_fide/`
- Metadata: `metadata_bona_fide.tsv`
- Verifikasi: 3 sampel random — semua 16.000 Hz , durasi 3.53–4.00 detik

4. Generasi Audio Spoof

4.1 Edge-TTS (Microsoft)

- **Voices:** `id-ID-GadisNeural` (wanita), `id-ID-ArdiNeural` (pria)
- **Strategi:** 2 suara per kalimat $\rightarrow 30.256 \times 2 = 60.512$ sampel
- **Concurrency:** 5 (async semaphore)
- **Pipeline:** MP3 $\rightarrow$ librosa load $\rightarrow$ FLAC save
- **Hasil:**  60.512 files

4.2 MMS-VITS (Meta)

- **Model:** `facebook/mms-tts-ind`
- **Target:** 5.000 sampel
- **Resume-friendly:** queue management
- **Hasil:**  5.000/5.000

4.3 gTTS (Google)

- **TLD Rotasi:** `com`, `co.id`, `com.au` (untuk variasi suara)
- **Request delay:** 0.3 detik (rate-limiting)
- **Target:** 5.000 sampel
- **Hasil:**  5.000/5.000

4.4 Kokoro-82M

- **Phoneme engine:** `espeak-ng` (American English — karena keterbatasan dukungan ID)
- **Voices:** `af_heart`, `af_bella`, `am_adam`, `am_michael`
- **Target:** 5.000 sampel
- **Hasil:**  5.000/5.000

Ringkasan Spoof

Sumber	Sampel
Edge-TTS	60.512
MMS-VITS	~5.000
gTTS	~5.000
Kokoro-82M	~5.000
Total	75.512

- Metadata: `metadata_spoof.tsv` (75.512 entries)

5. Pembagian Dataset

Proses

1. Load metadata bona-fide (30.256) dan spoof (75.512)
2. **Balancing 1:1:** subsample spoof → 30.256 sampel tiap kelas
3. Gabungkan dan shuffle (random seed=42)
4. Split 80/10/10

Hasil Split

Split	Total	Bona Fide	Spoof
Train	48.409	24.149	24.260

Split	Total	Bona Fide	Spoof
Val	6.051	3.045	3.006
Test	6.052	3.062	2.990
Total	60.512	30.256	30.256

- Lokasi: `/Users/reY/ITB/semester_2/PPT/dataset_voice/splits/`

6. Training Model AASIST

Arsitektur: SincConv → ResBlock encoder → AdaptiveAvgPool → Classifier

Input: Raw waveform, 4 detik @ 16 kHz (64.000 sampel)

Parameter total: 2.508.174

Progres Training

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	0.1035	96.17%	2.1122	72.43%
4	0.0075	99.75%	1.4631	79.41%
7	0.0038	99.89%	1.4619	80.63% ← best
early stop	—	—	—	—

- Early stopping pada epoch 12 (tidak ada improvement selama 5 epoch)
- Checkpoint: `{DIR_AASIST}/aasist_best.pt`

Hasil Test Set

	precision	recall	f1-score	support
bonafide	0.79	1.00	0.88	3062
spoof	0.81	0.62	0.70	2990
accuracy			0.80	6052

ROC-AUC : 0.9909

EER : 1.02%

Catatan: Recall spoof hanya 62% — model banyak false negative (spoof diklasifikasi bonafide).

7. Training Model MoLEx

Arsitektur: LCNN (Light CNN) + Attention Pooling

Input: Fitur LFCC [60 koefisien, 401 frame]

Parameter total: 179.491 (jauh lebih ringan dari AASIST)

Progres Training

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	0.0461	98.32%	0.0102	99.80%
5	0.0028	99.95%	0.0040	99.88%
12	0.0006	99.98%	0.0023	99.97% ← best
early stop	—	—	—	—

- Checkpoint: `{DIR_MOLEX}/molex_best.pt`

Hasil Test Set

	precision	recall	f1-score	support
bonafide	1.00	1.00	1.00	3062
spoof	1.00	1.00	1.00	2990
accuracy			1.00	6052
ROC-AUC : 1.0000				
EER : 0.03%				

8. Perbandingan AASIST vs MoLEx

Metrik	AASIST	MoLEx
Accuracy	79.81%	99.95%
ROC-AUC	0.9909	1.0000
EER	1.02%	0.03%
Parameters	2.508.174	179.491
Input type	Raw waveform	LFCC features

MoLEx unggul di semua metrik dengan parameter 14× lebih sedikit.

9. Inference Real-World

Setup

- AASIST dan MoLEx di-load dari checkpoint masing-masing
- Threshold: Low=0.3, High=0.7 (untuk klasifikasi **UNCERTAIN**)
- Format audio didukung: `.flac`, `.wav`, `.mp3`, `.m4a`, `.ogg`

Contoh Prediksi File Tunggal

File	AASIST	MoLEx	Ensemble	p_spoof
sample_gtid.mp3	BONAFIDE	BONAFIDE	BONAFIDE	0.0000

Contoh Batch Prediksi (25 file)

File	AASIST	MoLEx	Ensemble
fake_ardi_ttsfree.mp3	SPOOF	SPOOF	SPOOF
fake_guru_rani_minta_duit.mp3	SPOOF	BONAFIDE	UNCERTAIN
fake_rani_ttsfree.mp3	SPOOF	SPOOF	SPOOF
fake_sri_mulyani_guru itu beban.mp3	BONAFIDE	BONAFIDE	BONAFIDE

Ringkasan Batch

Label	Jumlah	Persentase
BONAFIDE	15	60.0%
SPOOF	5	20.0%
UNCERTAIN	5	20.0%

10. Ekstraksi Fitur untuk XGBoost

Total fitur: 26

Grup	Fitur
Akustik	Chroma, RMS, Centroid, Bandwidth, Rolloff, ZCR
MFCC	MFCC_1 s/d MFCC_20

Proses: Audio dipotong per segmen 1 detik → fitur dirata-rata antar segmen

Jumlah Data

Split	Sampel	Dimensi	Ukuran File
Train	48.409	(48409, 26)	5.0 MB
Val	6.051	(6051, 26)	0.6 MB
Test	6.052	(6052, 26)	0.6 MB

- Standardisasi: `StandardScaler` fit di train, transform val/test
- Disimpan: `features_{split}.npz`, `scaler.pkl`

Top 10 Fitur Paling Diskriminatif (berdasarkan delta mean bonafide vs spoof)

Rank	Fitur	Delta
1	ZCR	0.9820
2	MFCC_7	0.9651
3	Centroid	0.9119
4	Rolloff	0.8980
5	Bandwidth	0.8183
6	MFCC_9	0.8122
7	MFCC_13	0.8081
8	MFCC_11	0.7992
9	MFCC_3	0.7968
10	MFCC_1	0.7923

11. Training & Evaluasi XGBoost

Setup

- Training pada gabungan train+val (54.460 sampel) setelah mencari rounds optimal
- Pencarian rounds: 100–500 (step=10)
- **Optimal rounds:** 230 (via 10-fold CV)

Hasil 10-Fold Cross-Validation (230 rounds)

Metrik	Mean	Std
Accuracy	99.87%	±0.03%
ROC-AUC	1.0000	±0.0000
EER	0.12%	±0.05%

Hasil Test Set

	precision	recall	f1-score	support
bonafide	1.00	1.00	1.00	3062
spoof	1.00	1.00	1.00	2990
accuracy			1.00	6052
ROC-AUC	: 1.0000			
EER	: 0.13%			

Top 10 Fitur Penting (berdasarkan Gain)

Rank	Fitur	Gain
1	MFCC_7	0.2128
2	RMS	0.0966
3	MFCC_10	0.0733
4	MFCC_16	0.0727
5	MFCC_5	0.0597
6	MFCC_13	0.0566
7	Rolloff	0.0550
8	MFCC_2	0.0431
9	MFCC_15	0.0383
10	ZCR	0.0350

- Model disimpan: `xgboost_final.json`, `xgboost_final.pkl`

12. Perbandingan Tiga Model

Model	Accuracy	ROC-AUC	EER	Jenis Input
AASIST	79.81%	0.9909	1.02%	Raw waveform
MoLEx	99.95%	1.0000	0.03%	LFCC features
XGBoost	99.83%	1.0000	0.13%	MFCC + akustik

13. Catatan & Temuan Penting

Tentang Performa Model

- AASIST underperform:** Accuracy hanya 79.81% dengan recall spoof 62%. Ini mengindikasikan bahwa arsitektur SincConv + ResBlock kesulitan membedakan spoof dari bonafide pada dataset ini, kemungkinan karena domain mismatch — arsitektur AASIST aslinya dirancang untuk speech codec artifacts, bukan TTS modern.
- MoLEx & XGBoost hampir sempurna:** Kedua model berbasis fitur frekuensi mencapai ROC-AUC = 1.0 di test set. Ini bisa jadi terlalu optimistis — lihat poin "distributional leak" di bawah.
- Kemungkinan distributional leak:** Spoof dihasilkan dari kalimat yang sama dengan bona-fide (Common Voice). Karena fitur LFCC/MFCC sangat sensitif terhadap konten linguistik, model mungkin belajar membedakan TTS artifacts vs rekaman manusia murni, bukan generalisasi ke spoof yang belum pernah dilihat.
- Kokoro menggunakan phoneme English:** Kokoro-82M di-generate dengan espeak-ng Bahasa Inggris (bukan Indonesia). Suara yang dihasilkan bisa sangat berbeda dari TTS Indonesia asli,

sehingga mudah terdeteksi dan bisa menjadi salah satu faktor performa tinggi yang tidak realistis.

5. **Imbalance asli:** Dataset spoof (75.512) > bona-fide (30.256). Balancing dengan subsample 1:1 digunakan, yang berarti 45.256 sampel spoof dibuang. Strategi ini valid tapi mengurangi variasi spoof.

Tentang Inferensi Real-World

6. **Disagreement AASIST–MoLEx:** File `fake_guru_rani_minta_duit.mp3` menunjukkan ketidaksepakatan (AASIST=SPOOF, MoLEx=BONAFIDE). Ini kasus paling menarik — mungkin audio tersebut adalah edge case atau adversarial example.
7. **20% UNCERTAIN:** Dari 25 file test, 5 (20%) masuk kategori UNCERTAIN. Threshold 0.3/0.7 agak ketat — perlu dikalibrasi pada data real-world lebih banyak.

14. Rekomendasi Lanjutan

Prioritas Tinggi

1. Evaluasi Generalisasi dengan Data Luar

Dataset saat ini hanya dari satu sumber (Common Voice). Uji model dengan:

- Audio dari YouTube, podcast, atau call center Bahasa Indonesia
- Spoof dari TTS engine baru yang belum ada di training (zero-shot TTS evaluation)
- Audio adversarial yang sengaja didesain untuk mengelabui detektor

2. Perbaiki AASIST

AASIST saat ini jauh tertinggal. Coba:

- Fine-tune dari pre-trained checkpoint resmi (bukan training from scratch)
- Gunakan arsitektur AASIST versi terbaru (RawGAT-ST, W2V-AASIST)
- Tambah augmentasi data: noise, codec compression, room impulse response

3. Pisahkan Kalimat antara Bona Fide dan Spoof

Untuk mencegah distributional leak: gunakan subset kalimat berbeda untuk generate spoof, sehingga model tidak bisa "menghafal" konten linguistik.

Prioritas Sedang

4. Tambah TTS Engine Indonesia yang Lebih Realistis

- **ElevenLabs** (dengan suara kloning Indonesia)
- **OpenAI TTS** dengan bahasa Indonesia
- Ganti Kokoro dengan TTS yang benar-benar mendukung Bahasa Indonesia
- Pertimbangkan voice conversion (VC) attacks, bukan hanya TTS

5. Ensemble yang Lebih Cerdas

Saat ini ensemble menggunakan threshold sederhana. Pertimbangkan:

- Weighted voting berdasarkan confidence tiap model
- Stacking: gunakan output probabilitas AASIST + MoLEx + XGBoost sebagai input meta-classifier
- Kalibrasi probabilitas dengan Platt scaling

6. Analisis Error AASIST Lebih Dalam

Investigasi false negatives (spoof yang lolos):

- Apakah ada pola tertentu dari sumber TTS tertentu?
- Apakah audio dengan durasi pendek lebih sering salah?
- Apakah ada korelasi dengan speaker/voice tertentu?

Prioritas Rendah / Eksploratif

7. Lightweight Deployment

XGBoost (26 fitur) adalah kandidat terbaik untuk edge deployment:

- Konversi ke ONNX atau TreeLite
- Uji latensi real-time pada mobile/embedded device

8. Continual Learning

Deepfake audio terus berkembang. Pertimbangkan:

- Pipeline untuk update model secara berkala dengan data baru
- Deteksi distribution shift (apakah model mulai degradasi?)

9. Explainability

Untuk konteks forensik dan hukum:

- SHAP values untuk XGBoost (sudah didukung langsung)
- Grad-CAM atau attention visualization untuk MoLEx
- Laporan per-file yang menunjukkan fitur mana yang memicu deteksi spoof

Lampiran: Statistik Dataset

Metrik	Nilai
Total bona-fide (raw)	30.256
Total spoof (raw)	75.512
Dataset setelah balancing	60.512
Train / Val / Test	48.409 / 6.051 / 6.052

Metrik	Nilai
Sample rate	16.000 Hz
Durasi maksimum	4 detik
Format audio	FLAC (PCM_16)

Lampiran: Path File Penting

```
dataset_voice/
├── bona_fide/                ← 30.256 file FLAC
├── spoof/                   ← 75.512 file FLAC
├── metadata_bona_fide.tsv
├── metadata_spoof.tsv
├── splits/
│   ├── train.tsv
│   ├── val.tsv
│   └── test.tsv
├── features/
│   ├── features_train.npz
│   ├── features_val.npz
│   ├── features_test.npz
│   └── scaler.pkl
models_voice/
├── aasist/
│   └── aasist_best.pt
├── molex/
│   └── molex_best.pt
├── xgboost/
│   ├── xgboost_final.json
│   └── xgboost_final.pkl
```