

Laporan Pipeline: Deteksi Deepfake Audio Bahasa Indonesia

Tanggal: 24 April 2026
Notebook: [pipeline_lengkap.ipynb](#)
Bahasa: Python 3.10.12 | PyTorch 2.11.0 | Device: Apple MPS

Daftar Isi

- 1. [Ringkasan Eksekutif](#)
- 2. [Konfigurasi Global](#)
- 3. [Preprocessing Audio Bona Fide](#)
- 4. [Generasi Audio Spoof](#)
- 5. [Pembagian Dataset](#)
- 6. [Training Model AASIST](#)
- 7. [Training Model MoLEx](#)
- 8. [Perbandingan AASIST vs MoLEx](#)
- 9. [Inference Real-World](#)
- 10. [Ekstraksi Fitur untuk XGBoost](#)
- 11. [Training & Evaluasi XGBoost](#)
- 12. [Perbandingan Tiga Model](#)
- 13. [Catatan & Temuan Penting](#)
- 14. [Rekomendasi Lanjutan](#)

1. Ringkasan Eksekutif

Pipeline ini membangun sistem deteksi deepfake audio Bahasa Indonesia end-to-end: mulai dari pengumpulan data, generasi audio sintetis (spoof), pelatihan tiga jenis model, hingga inferensi real-world. Dataset bersumber dari **Mozilla Common Voice v24.0** (Indonesian, 30.256 sampel) dan **LibriVox** (5.635 sampel tambahan), menghasilkan 35.891 sampel bona-fide yang kemudian diperkaya dengan 75.512 sampel spoof dari 4 TTS engine berbeda.

Hasil akhir menunjukkan bahwa ketiga model berhasil mencapai performa sangat tinggi, semua dengan ROC-AUC = 1.0000. AASIST (raw waveform) kini juga mencapai EER 0.00% pada test set — peningkatan drastis dari run sebelumnya, menunjukkan bahwa inisialisasi dan scheduling yang lebih stabil sangat berpengaruh.

Model	Accuracy	ROC-AUC	EER	MCC	ms/sampel
AASIST	99.79%	1.0000	0.00%	0.9958	4.5964
MoLEx	99.96%	1.0000	0.03%	0.9992	3.2693
XGBoost	99.90%	1.0000	0.10%	0.9981	0.0026

2. Konfigurasi Global

Direktori Utama

Variabel	Path
CV_CORPUS_ROOT	/Users/rei/ITB/semester_2/PPT/dataset
DATASET_ROOT	/Users/rei/ITB/semester_2/PPT/dataset_voice
MODELS_ROOT	/Users/rei/ITB/semester_2/PPT/models_voice

Parameter Audio

Parameter	Nilai
Sample rate	16.000 Hz
Durasi maksimum	4 detik (64.000 sampel)
Format output	FLAC (PCM_16)

Parameter LFCC (MoLEx)

Parameter	Nilai
n_lfcc	60
n_filter	70
n_fft	512
win_length	320
hop_length	160

Hyperparameter Training (DL)

Parameter	Nilai
Batch size (AASIST)	24
Batch size (MoLEx)	32
Epochs	20
Learning rate	1e-4
Weight decay	1e-4
Optimizer	AdamW
Scheduler	CosineAnnealingLR (T_max=20)
Early stopping patience	5

Hyperparameter XGBoost

Parameter	Nilai
<code>max_depth</code>	6
<code>learning_rate</code>	0.1
<code>subsample</code>	0.8
<code>colsample_bytree</code>	0.8
CV folds	10
Boosting rounds (optimal)	313

3. Preprocessing Audio Bona Fide

Sumber data:

- Mozilla Common Voice v24.0 — korpus Bahasa Indonesia
- LibriVox — rekaman audiobook publik Bahasa Indonesia (5.635 file)

File TSV yang dibaca: `validated.tsv`, `train.tsv`, `test.tsv`

Proses

1. Baca semua TSV menggunakan `csv.DictReader`
2. Deduplikasi berdasarkan tuple (`prefix`, `audio_filename`)
3. Tambahkan rekaman LibriVox (file MP3/FLAC yang sudah dikumpulkan)
4. Load audio dengan `librosa.load(sr=16000, mono=True)`
5. Simpan ulang sebagai FLAC (PCM_16) ke direktori `bona_fide/`
6. Tulis metadata TSV: `[file_id, flac_filename, sentence]`

Hasil

Sumber	Records	Duplikat
<code>validated.tsv</code> (Common Voice)	30.256	0
<code>train.tsv</code>	4.973	4.973 (semua duplikat dari <code>validated</code>)
<code>test.tsv</code>	3.691	3.691 (semua duplikat dari <code>validated</code>)
LibriVox	5.635	0
Total unik	35.891	—

- Output: `/Users/rex/ITB/semester_2/PPT/dataset_voice/bona_fide/`
- Metadata: `metadata_bona_fide.tsv`
- Verifikasi: 3 sampel random — semua 16.000 Hz , durasi 3.46–5.98 detik
- Catatan: 5.635 rekaman LibriVox **dikecualikan** dari generasi TTS spoof (hanya CommonVoice yang di-TTS)

4. Generasi Audio Spoof

4.1 Edge-TTS (Microsoft)

- **Voices:** `id-ID-GadisNeural` (wanita), `id-ID-ArdiNeural` (pria)
- **Strategi:** 2 suara per kalimat → $30.256 \times 2 = 60.512$ sampel
- **Concurrency:** 5 (async semaphore)
- **Pipeline:** MP3 → librosa load → FLAC save
- **Hasil:**  60.512 files

4.2 MMS-VITS (Meta)

- **Model:** `facebook/mms-tts-ind`
- **Target:** 5.000 sampel
- **Resume-friendly:** queue management
- **Hasil:**  5.000/5.000

4.3 gTTS (Google)

- **TLD Rotasi:** `com`, `co.id`, `com.au` (untuk variasi suara)
- **Request delay:** 0.3 detik (rate-limiting)
- **Target:** 5.000 sampel
- **Hasil:**  5.000/5.000

4.4 Kokoro-82M

- **Phoneme engine:** `espeak-ng` (American English — karena keterbatasan dukungan ID)
- **Voices:** `af_heart`, `af_bella`, `am_adam`, `am_michael`
- **Target:** 5.000 sampel
- **Hasil:**  5.000/5.000

Ringkasan Spoof

Sumber	Sampel
Edge-TTS (GadisNeural)	30.256
Edge-TTS (ArdiNeural)	30.256
MMS-VITS	5.000
gTTS	5.000
Kokoro-82M	5.000
Total	75.512

- Metadata: `metadata_spoof.tsv` (75.512 entries)

5. Pembagian Dataset

Proses

- 1. Load metadata bona-fide (35.891) dan spoof (75.512)
- 2. **Balancing 1:1**: subsample spoof → 35.891 sampel tiap kelas
- 3. Gabungkan dan shuffle (random seed=42)
- 4. Split 80/10/10

Hasil Split

Split	Total	Bona Fide	Spoof
Train	57.425	28.687	28.738
Val	7.178	—	—
Test	7.179	3.621	3.558
Total	71.782	35.891	35.891

- Lokasi: /Users/reY/ITB/semester_2/PPT/dataset_voice/splits/

6. Training Model AASIST

Arsitektur: SincConv → ResBlock encoder → AdaptiveAvgPool → Classifier

Input: Raw waveform, 4 detik @ 16 kHz (64.000 sampel)

Parameter total: 2.508.174

Progres Training

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	0.0942	96.61%	2.5823	68.51% ← best
2	0.0149	99.54%	3.3498	67.21%
3	0.0101	99.70%	8.9870	50.59%
4	0.0075	99.80%	1.1331	80.61% ← best
5	0.0058	99.82%	4.8582	65.30%
6	0.0043	99.88%	0.0062	99.86% ← best
7	0.0036	99.91%	6.5887	65.81%
8	0.0023	99.94%	43.5975	53.13%
9	0.0032	99.94%	16.1982	54.88%
10	0.0017	99.95%	1.2600	86.14%
11	0.0012	99.96%	0.0308	99.40%
early stop	—	—	—	—

- Early stopping pada epoch 11 (tidak ada improvement selama 5 epoch)
- Best checkpoint: epoch 6 (val acc 99.86%)
- Checkpoint: {DIR_AASIST}/aasist_best.pt

Hasil Test Set

	precision	recall	f1-score	support
bonafide	1.00	1.00	1.00	3621
spoof	1.00	1.00	1.00	3558
accuracy			1.00	7179
ROC-AUC	: 1.0000			
EER	: 0.00%			
MCC	: 0.9958			
Waktu inf.	: 32997.6 ms total 4.5964 ms/sampel			

7. Training Model MoLEx

Arsitektur: LCNN (Light CNN) + Attention Pooling
Input: Fitur LFCC [60 koefisien, 401 frame]
Parameter total: 179.491 (jauh lebih ringan dari AASIST)

Progres Training

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	0.0469	98.40%	0.0159	99.62% ← best
2	0.0102	99.77%	0.0064	99.85% ← best
3	0.0065	99.86%	0.0024	99.93% ← best
4	0.0044	99.90%	0.0053	99.89%
5	0.0026	99.93%	0.0055	99.92%
6	0.0024	99.95%	0.0001	99.99% ← best
7	0.0019	99.96%	0.0056	99.92%
8	0.0004	99.99%	0.0001	100.00% ← best
9	0.0000	100.00%	0.0000	100.00%
10	0.0009	99.98%	0.0001	100.00%
11	0.0014	99.98%	0.0006	99.99%
12	0.0006	99.99%	0.0002	99.99%
13	0.0000	100.00%	0.0014	99.97%

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
early stop	—	—	—	—

- Early stopping pada epoch 13 (tidak ada improvement selama 5 epoch)
- Best checkpoint: epoch 8 (val acc 100.00%)
- Checkpoint: `{DIR_MOLEX}/molex_best.pt`

Hasil Test Set

	precision	recall	f1-score	support
bonafide	1.00	1.00	1.00	3621
spoof	1.00	1.00	1.00	3558
accuracy			1.00	7179
ROC-AUC	: 1.0000			
EER	: 0.03%			
MCC	: 0.9992			
Waktu inf.	: 23470.2 ms total 3.2693 ms/sampel			

8. Perbandingan AASIST vs MoLEx

Metrik	AASIST	MoLEx
Accuracy	99.79%	99.96%
ROC-AUC	1.0000	1.0000
EER	0.00%	0.03%
MCC	0.9958	0.9992
Parameters	2.508.174	179.491
ms/sampel	4.5964	3.2693
Input type	Raw waveform	LFCC features

MoLEx unggul di accuracy dan MCC dengan parameter 14x lebih sedikit. Namun AASIST kini mencapai EER 0.00% — keduanya praktis setara secara performa.

9. Inference Real-World

Setup

- AASIST dan MoLEx di-load dari checkpoint masing-masing
- Threshold: Low=0.3, High=0.7 (untuk klasifikasi **TIDAK YAKIN**)
- Format audio didukung: `.flac`, `.wav`, `.mp3`, `.m4a`, `.ogg`

Contoh Prediksi File Tunggal

File	AASIST	MoLEx	Ensemble	p_spoof
sample_gtid.mp3	BONAFIDE	BONAFIDE	BONAFIDE	0.0000

Prediksi Batch (25 file)

File	AASIST	MoLEx	Ensemble
fake_ardi_ttsfree.mp3	SPOOF (0.9999)	SPOOF (1.0000)	SPOOF
fake_guru_rani_minta_duit.mp3	SPOOF (0.9956)	BONAFIDE (0.0000)	TIDAK YAKIN
fake_rani_ttsfree.mp3	SPOOF (1.0000)	SPOOF (1.0000)	SPOOF
fake_sri_mulyani_guru itu beban.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
fake_ttsfree_standard-b.mp3	BONAFIDE (0.0016)	BONAFIDE (0.0253)	BONAFIDE
fake_ttsfree_standard-c.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
fake_ttsfree_standard-d.mp3	SPOOF (1.0000)	BONAFIDE (0.0232)	TIDAK YAKIN
real_CNN.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
real_Industri.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
real_Ketagihan.mp3	BONAFIDE (0.1190)	BONAFIDE (0.0000)	BONAFIDE
real_PENIPU_Tutorial.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
real_Pak_Jokowi.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
real_SAYA AKAN LAWAN.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
real_berita_satu.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
real_boy_william.mp3	BONAFIDE (0.0115)	BONAFIDE (0.0000)	BONAFIDE
real_denny_sumargo.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE

File	AASIST	MoLEx	Ensemble
real_kominfo_jatim.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
real_podkesmas.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
real_rans.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
real_tvri.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
real_vindes.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
sample_budi_utomo.mp3	SPOOF (0.9886)	BONAFIDE (0.1563)	TIDAK YAKIN
sample_dewi_putri.mp3	SPOOF (1.0000)	SPOOF (1.0000)	SPOOF
sample_gadgetin.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE
sample_gtid.mp3	BONAFIDE (0.0000)	BONAFIDE (0.0000)	BONAFIDE

Ringkasan Batch

Label	Jumlah	Persentase
BONAFIDE	19	76.0%
SPOOF	3	12.0%
TIDAK YAKIN	3	12.0%

- Hasil disimpan:
/Users/reY/ITB/semester_2/PPT/models_voice/realworld_test/batch_results.csv

10. Ekstraksi Fitur untuk XGBoost

Total fitur: 26

Grup	Fitur
Akustik	Chroma, RMS, Centroid, Bandwidth, Rolloff, ZCR
MFCC	MFCC_1 s/d MFCC_20

Proses: Audio dipotong per segmen 1 detik → fitur dirata-rata antar segmen

Jumlah Data

Split	Sampel	Dimensi	Ukuran File
Train	57.425	(57425, 26)	—
Val	7.178	(7178, 26)	—
Test	7.179	(7179, 26)	—

- Standardisasi: `StandardScaler` fit di train, transform val/test
- Disimpan: `features_{split}.npz`, `scaler.pkl`

Top 10 Fitur Paling Diskriminatif (berdasarkan delta mean bonafide vs spoof)

Rank	Fitur	Delta
1	MFCC_7	1.0412
2	ZCR	0.9186
3	Centroid	0.8418
4	Rolloff	0.7996
5	Bandwidth	0.7804
6	RMS	0.7691
7	MFCC_6	0.7446
8	MFCC_5	0.7262
9	MFCC_2	0.6625
10	MFCC_15	0.6307

11. Training & Evaluasi XGBoost

Setup

- Training pada gabungan train+val (64.603 sampel) setelah mencari rounds optimal
- Pencarian rounds: early stopping (max=500, patience=50)
- **Optimal rounds:** 313 (via early stopping)

Hasil 10-Fold Cross-Validation (313 rounds)

Metrik	Mean	Std
Accuracy	99.90%	±0.05%
ROC-AUC	1.0000	±0.0000
EER	0.10%	±0.06%

Hasil Test Set

	precision	recall	f1-score	support
bonafide	1.00	1.00	1.00	3621
spoof	1.00	1.00	1.00	3558
accuracy			1.00	7179
ROC-AUC	: 1.0000			
EER	: 0.10%			
MCC	: 0.9981			
Waktu inf.	: 18.9 ms total 0.0026 ms/sampel			

Top 10 Fitur Penting (berdasarkan Gain)

Rank	Fitur	Gain
1	MFCC_7	0.2520
2	RMS	0.0984
3	MFCC_16	0.0733
4	MFCC_5	0.0724
5	MFCC_10	0.0692
6	Rolloff	0.0566
7	MFCC_13	0.0461
8	MFCC_2	0.0400
9	MFCC_17	0.0372
10	MFCC_15	0.0347

- Model disimpan: `xgboost_final.json`, `xgboost_final.pkl`

12. Perbandingan Tiga Model

Model	Accuracy	ROC-AUC	EER	MCC	Inf. (ms/sampel)	Jenis Input
AASIST	99.79%	1.0000	0.00%	0.9958	4.5964	Raw waveform
MoLEx	99.96%	1.0000	0.03%	0.9992	3.2693	LFCC features
XGBoost	99.90%	1.0000	0.10%	0.9981	0.0026	MFCC + akustik

13. Catatan & Temuan Penting

Tentang Performa Model

1. **Semua model kini ROC-AUC = 1.000:** Dibandingkan run sebelumnya (AASIST 0.9997), kini ketiga model mencapai discriminability sempurna di test set. Ini konsisten dengan penambahan data LibriVox yang menambah variasi rekaman bona-fide.
2. **AASIST drastis membaik:** EER turun dari 0.56% → 0.00% dan accuracy naik dari 98.93% → 99.79%. Best checkpoint kini di epoch 6 (val loss 0.0062, val acc 99.86%), bukan epoch 2 seperti sebelumnya. Pola val loss masih volatil (lonjakan besar di epoch 3, 7–9), tapi ada satu epoch di mana model "menemukan" representasi yang tepat.
3. **MoLEx stabil dan konsisten:** Best checkpoint di epoch 8 dengan val acc 100.00%. Training lebih smooth dibandingkan AASIST, tidak ada lonjakan val loss yang dramatis.
4. **Kemungkinan distributional leak tetap ada:** Spoof dihasilkan dari kalimat yang sama dengan bona-fide CommonVoice. Model mungkin belajar membedakan TTS artifacts vs rekaman manusia murni, bukan generalisasi ke spoof yang belum pernah dilihat.
5. **Kokoro menggunakan phoneme English:** Kokoro-82M di-generate dengan espeak-ng Bahasa Inggris. Suara yang dihasilkan berbeda signifikan dari TTS Indonesia asli, sehingga mudah terdeteksi.

Tentang Inferensi Real-World

6. **Perubahan signifikan vs run sebelumnya:** Beberapa file yang sebelumnya terdeteksi SPOOF kini tidak terdeteksi:
 - **fake_ttsfree_standard-b.mp3:** sebelumnya SPOOF (AASIST 0.824, MoLEx 0.990), kini BONAFIDE (0.0016, 0.0253)
 - **fake_ttsfree_standard-c.mp3:** sebelumnya TIDAK YAKIN, kini BONAFIDE (0.0000, 0.0000)
 - **sample_budi_utomo.mp3:** sebelumnya SPOOF (keduanya agree), kini TIDAK YAKIN (AASIST 0.989, MoLEx 0.156)

Ini mengindikasikan model baru memiliki decision boundary yang berbeda — lebih sensitif ke beberapa jenis spoof, kurang sensitif ke jenis lain.
7. **False negative meningkat pada TTSTFree:** Tiga file TTSTFree (**standard-b**, **standard-c**, **standard-d**) kini memiliki performa campuran — hanya **standard-d** yang masih TIDAK YAKIN. TTSTFree mungkin menggunakan model TTS yang lebih realistis dari data training.
8. **real_Ketagihan.mp3 dan real_boy_william.mp3 kini BONAFIDE:** Kedua file yang sebelumnya TIDAK YAKIN kini diklasifikasikan BONAFIDE dengan kepercayaan tinggi. Ini positif untuk recall audio nyata.
9. **XGBoost paling cepat:** Waktu inferensi 0.0026 ms/sampel — sangat efisien untuk deployment real-time (1.770× lebih lambat dari run sebelumnya karena dataset lebih besar, tapi masih jauh lebih cepat dari DL models).

14. Rekomendasi Lanjutan

Prioritas Tinggi

1. Evaluasi Generalisasi dengan Data Luar

Dataset saat ini dari dua sumber (Common Voice + LibriVox). Uji model dengan:

- Audio dari YouTube, podcast, atau call center Bahasa Indonesia
- Spoof dari TTS engine baru yang belum ada di training (zero-shot TTS evaluation)
- TTSTFree secara khusus — model kesulitan mendeteksinya

2. Stabilkan Training AASIST

AASIST menunjukkan val loss yang sangat volatile. Coba:

- Gradient clipping untuk mengurangi oscillasi
- Learning rate warmup sebelum decay
- Fine-tune dari pre-trained checkpoint resmi (bukan training from scratch)
- Tambah augmentasi data: noise, codec compression, room impulse response

3. Pisahkan Kalimat antara Bona Fide dan Spoof

Untuk mencegah distributional leak: gunakan subset kalimat berbeda untuk generate spoof, sehingga model tidak bisa "menghafal" konten linguistik.

Prioritas Sedang

4. Tambah TTS Engine Indonesia yang Lebih Realistis

- **ElevenLabs** (dengan suara kloning Indonesia)
- **OpenAI TTS** dengan bahasa Indonesia
- Ganti Kokoro dengan TTS yang benar-benar mendukung Bahasa Indonesia
- Pertimbangkan voice conversion (VC) attacks, bukan hanya TTS

5. Ensemble yang Lebih Cerdas

Saat ini ensemble menggunakan threshold sederhana. Pertimbangkan:

- Weighted voting berdasarkan confidence tiap model
- Stacking: gunakan output probabilitas AASIST + MoLEx + XGBoost sebagai input meta-classifier
- Kalibrasi probabilitas dengan Platt scaling

6. Investigasi Kasus TTSTFree

Model gagal mendeteksi `fake_ttsfree_standard-b` dan `-c` sebagai spoof. Perlu:

- Analisis spektral file-file ini vs training spoof
- Cek apakah TTSTFree menggunakan arsitektur TTS yang mirip dengan training data atau justru jauh berbeda

Prioritas Rendah / Eksploratif

7. Lightweight Deployment

XGBoost (26 fitur, 0.0026 ms/sampel) adalah kandidat terbaik untuk edge deployment:

- Konversi ke ONNX atau TreeLite
- Uji latensi real-time pada mobile/embedded device

8. Continual Learning

Deepfake audio terus berkembang. Pertimbangkan:

- Pipeline untuk update model secara berkala dengan data baru
- Deteksi distribution shift (apakah model mulai degradasi?)

9. Explainability

Untuk konteks forensik dan hukum:

- SHAP values untuk XGBoost (sudah didukung langsung)
- Grad-CAM atau attention visualization untuk MoLEx
- Laporan per-file yang menunjukkan fitur mana yang memicu deteksi spoof

Lampiran: Statistik Dataset

Metrik	Nilai
Total bona-fide (raw)	35.891
— Common Voice	30.256
— LibriVox	5.635
Total spoof (raw)	75.512
Dataset setelah balancing	71.782
Train / Val / Test	57.425 / 7.178 / 7.179
Sample rate	16.000 Hz
Durasi maksimum	4 detik
Format audio	FLAC (PCM_16)

Lampiran: Path File Penting

```
dataset_voice/  
├── bona_fide/           ← 35.891 file FLAC  
├── spoof/              ← 75.512 file FLAC  
├── metadata_bona_fide.tsv  
├── metadata_spoof.tsv  
├── splits/  
│   ├── train.tsv  
│   └── val.tsv
```

```
|   └─ test.tsv
|   └─ features/
|       ├── features_train.npz
|       ├── features_val.npz
|       ├── features_test.npz
|       └─ scaler.pkl

models_voice/
├─ aasist/
│   └─ aasist_best.pt
├─ molex/
│   └─ molex_best.pt
├─ xgboost/
│   ├── xgboost_final.json
│   └─ xgboost_final.pkl
├─ comparison/
│   └─ comparison_summary.json
├─ realworld_test/
│   └─ batch_results.csv
```